Resultados do AprendFed

LeanFed-c contra FedAvg com bateria limitada: o que os experimentos mostram

Até 24 de outubro de 2026 — CIFAR-10 e FEMNIST com 8 seeds — branch *leanfed-baseline* (commit 86ab3a9)

Resumo. Com bateria simulada e custo de comunicação realista, o LeanFed original **não melhora** sobre o FedAvg (+0,3 ponto com 8 seeds). A versão corrigida (**LeanFed-c**), que reserva a comunicação e o custo fixo antes de escolher quantos dados treinar, mantém praticamente todos os clientes vivos até o fim. Com 8 seeds no CIFAR-10, isso vale **+9,1 pontos** de acurácia com Dirichlet α = 0,05 (positivo nas 8 seeds) e **+4,3** com α = 0,1 (6 de 8; IC 95% de −0,1 a +8,8). Quando os dados de cada classe estão espalhados entre os clientes, o ganho some: +0,6 com α = 0,3 e −0,4 com α = 1,0. Pular as rodadas em que o cliente treinaria menos da metade dos dados (**fração mínima 0,5**) melhora o LeanFed-c **nos quatro α**, de +7,3 pontos (α = 0,05) a +0,5 (α = 1,0): sobre o FedAvg, ganha +16,3, +6,8 e +1,6 de α = 0,05 a α = 0,3 e empata com α = 1,0, onde o LeanFed-c sozinho perdia. No FEMNIST, com a acurácia medida depois de recalibrar a BatchNorm (seção 1), ela também é a melhor: +4,0 pontos sobre o FedAvg com Dirichlet α = 0,1 (8 de 8 seeds) e +0,2 na partição por escritor, onde os três métodos ficam a menos de meio ponto. Com ela, os clientes de bateria pequena pulam o começo do treino e chegam ao fim com energia para treinar todos os dados; quanto maior a fração mínima, maior o ganho (com 1,0, +8,5 sobre o FedAvg em α = 0,1). Esse ganho extra se espalha por todas as classes, e não só pelas desses clientes, e sobe sobretudo a pior classe. Ele vem de treinar mais exemplos no total: cada rodada pulada economiza a energia de rede, que vira treino. Sem rádio, o total fica igual e o ganho cai para +1,2 ponto (fração 0,5, sem significância); com a margem de cauda, ninguém morre e o ganho fica (+2,9). Entre cenários, o ganho acompanha a fração de classes concentradas nos clientes que o FedAvg perde por falta de bateria, e não a quantidade de dados que esses clientes levam; seed a seed, essa fração não prevê o ganho.

Conteúdo

- 1. Cenário, políticas e métricas
- 2. O LeanFed-c ganha porque não perde clientes no fim
- 3. Ajustes do LeanFed-c: a fração mínima ajuda em todos os cenários
- 4. O ganho depende da concentração de classes
- 5. Conclusões, limitações e próximos passos
- Apêndice A. Runs e como reproduzir

A ordem dos experimentos e o motivo de cada decisão estão em *historico_projeto.pdf*, na mesma pasta.

1. Cenário, políticas e métricas

Cenário de referência. FedAvg com Flower, um container Docker por cliente. 15 clientes, baterias de 1500/1000/500 J (5 clientes de cada), rede de 25 Mbps, MobileNetV3-Small pré-treinada a 96 px, 20 rodadas, uma época local, todos os clientes sorteados em toda rodada. Dataset padrão: CIFAR-10 dividido por Dirichlet $\alpha = 0{,}1$.

Energia. O treino custa 8,88 mJ por amostra (perfil medido na GPU com NVML, acima do repouso). A comunicação é potência do rádio (1,8 W) × bits / vazão, com a vazão sorteada em U(1, 25) Mbps a cada rodada: em média 23,6 J por rodada, com cauda longa (quase 100 J com vazão perto de 1 Mbps). Quando a bateria acaba, o cliente morre no meio da rodada.

Política	Fração η dos dados treinada por rodada	Ideia
FedAvg	1	treina tudo até a bateria acabar
LeanFed	orçamento / A	LeanFed original: supõe que só o treino gasta energia
LeanFed-c	(orçamento − C − D) / A	LeanFed corrigido: reserva antes a rede (C) e o custo fixo (D)

O orçamento da rodada é a bateria atual dividida pelas participações que faltam; A é a energia de treinar todos os dados locais. Com $\eta = 0$, o cliente pula a rodada sem gastar nada.

Métricas.

- **Acurácia**: média da acurácia no teste nas **3 últimas rodadas**. A da última rodada sozinha oscila vários pontos conforme quais clientes ainda estão vivos. No FEMNIST, medida com a BatchNorm recalibrada (abaixo).
- **Ganho**: acurácia do LeanFed-c menos a do FedAvg **com a mesma seed** (mesma partição e mesma sequência de vazões), com intervalo de confiança de 95% pela t de Student sobre as diferenças pareadas.
- **Seeds**: valores são média ± desvio amostral sobre as seeds 42 a 49 (n = 8), em todos os cenários. Diferenças entre duas variantes do LeanFed-c também são pareadas por seed.
- **Cliente perdido**: não contribuiu em nenhuma das 3 últimas rodadas. **Classes concentradas**: fração das classes com mais de 80% dos seus exemplos de treino nos clientes perdidos pelo FedAvg.

Avaliação no FEMNIST: BatchNorm recalibrada

A FedAvg tira a média das estatísticas das camadas BatchNorm (média e variância das ativações) junto com a dos pesos. No FEMNIST não-IID, essa média não representa os dados, e a acurácia do modelo global no teste fica subestimada e às vezes desaba numa rodada, com todos os clientes treinando normalmente: na rodada 1, 9% contra 33% recalibrado (FedAvg com Dirichlet, média das seeds); das rodadas 5 a 20, 32 das 768 avaliações caem abaixo de 30%, a pior a 2,4%.

Por isso, nas runs do FEMNIST o servidor também avalia o modelo depois de refazer essas estatísticas com 2048 exemplos de treino dos clientes, sorteados pela seed (sem usar o

teste). Os pesos não mudam, e o modelo enviado aos clientes também não: a recalibração só entra na medida. Com ela, a pior avaliação das rodadas 5 a 20 fica em 57,6%, e a média das 3 últimas rodadas sobe de 5 a 16 pontos, conforme o método. Todas as acurácias do FEMNIST neste documento são as recalibradas.

> **Sem recalibrar, o FEMNIST não compara métodos.** O desvio entre seeds chega a 18 pontos (contra 2 recalibrado), e a ordem muda: com Dirichlet, a fração mínima 0,5 ficaria em último (62,7% contra 69,5% do FedAvg); por escritor, em primeiro (78,8% contra 74,6%). No CIFAR-10, as quedas de acurácia são reais (vêm dos clientes que saem) e recalibrar não as recupera; ele usa a avaliação original.

2. O LeanFed-c ganha porque não perde clientes no fim

CIFAR-10, α = 0,1, seeds 42 a 49	Média das 3 últimas	Acurácia máxima	Rodadas *dead*	Sem bateria no fim
FedAvg	70,4 ± 6,0%	78,2 ± 1,4%	45,5	7,8
LeanFed	70,8 ± 6,5%	77,6 ± 1,6%	29,4	7,8
LeanFed-c	**74,8 ± 3,6%**	77,5 ± 2,5%	0,8	1,6

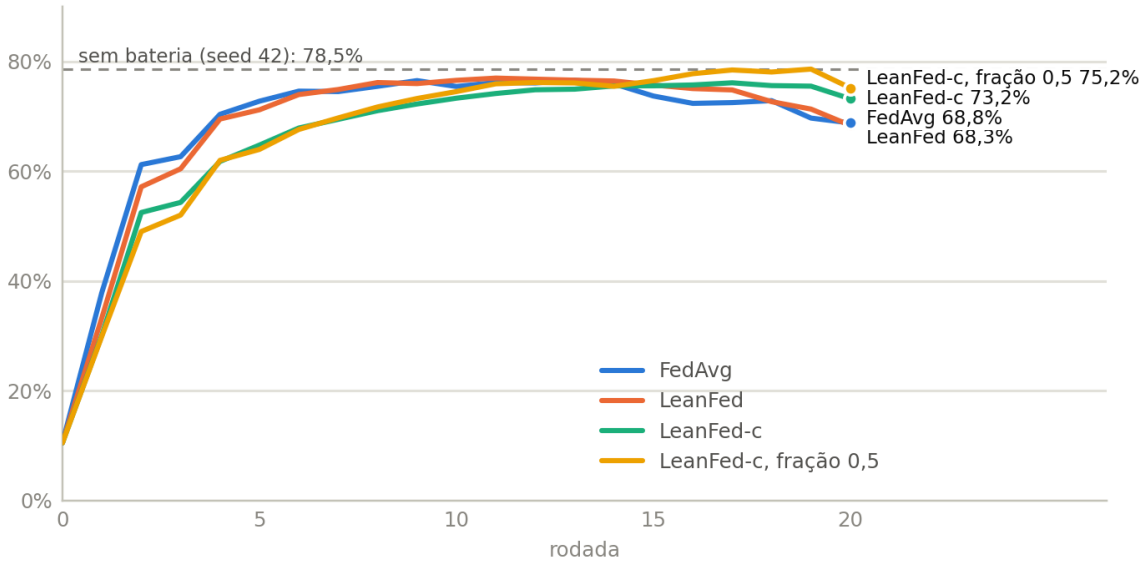


Figura 1. Acurácia no teste por rodada, média das seeds 42 a 49 (CIFAR-10, α = 0,1). FedAvg, LeanFed e LeanFed-c chegam a picos parecidos (76,6%, 77,0% e 76,1%). A diferença está no fim, quando os clientes de bateria pequena morrem no FedAvg e no LeanFed. O LeanFed-c com fração mínima 0,5 (seção 3) chega a um pico maior (78,6%). Todas as curvas caem na rodada 20.

- **O LeanFed-c ganha em 6 das 8 seeds**: +10,8, +2,0 e +13,0 pontos nas seeds 42 a 44; −1,8, +4,1, +1,7, +5,8 e −1,0 nas seeds 45 a 49. A média cai de +8,6 (n = 3) para **+4,3**, com IC 95% de −0,1 a +8,8 (t pareado, p = 0,055).

- **O pico não melhora**: 77,5% no LeanFed-c contra 78,2% no FedAvg. O ganho vem de não perder acurácia nas últimas rodadas, e não de aprender mais.
- **O LeanFed original não ajuda**: +0,3 ponto sobre o FedAvg (IC 95% de −0,6 a +1,3). Gasta o orçamento todo em treino, paga a rede por fora e termina com os mesmos 7,8 clientes sem bateria do FedAvg. Morre menos rodadas no meio do caminho (29 contra 45), mas isso não muda a acurácia. Aqui a comunicação é de um terço a metade do custo de uma rodada.
- **A energia total é a mesma** (11,3 kJ no FedAvg, 11,2 no LeanFed-c): o LeanFed-c distribui a bateria ao longo das 20 rodadas, com 285 participações contra 247 do FedAvg.

Por que sobram perdas. Na seed 43 (ganho de só 2 pontos), três clientes do LeanFed-c morrem nas rodadas 18 a 20, cada um por **uma** rodada de vazão perto de 1 Mbps (52 a 127 J de rede contra 23,6 J reservados), quando a bateria já não tinha folga. Dois deles tinham 94% dos pássaros e 92% dos cervos, que caem a 48% e 18% de acurácia no modelo final.

Quando o LeanFed-c perde. Nas seeds 45 e 49, o FedAvg quase não cai no fim: na 49, a última rodada é o seu máximo (78,0%); na 45, ele fica em 77,3% nas 3 últimas, embora perca 74% dos dados e 60% das classes fiquem concentradas nos clientes que saem. O LeanFed-c, que treina só parte dos dados por rodada, chega a picos menores (79,6% e 77,8% contra 81,0% e 78,0%) e, na seed 45, ainda perde 2 clientes no fim. Com a fração mínima 0,5 (seção 3), as duas seeds passam a ganhar (+2,5 e +0,1).

3. Ajustes do LeanFed-c: a fração mínima ajuda em todos os cenários

A **fração mínima** faz o cliente pular a rodada quando a fração η que cabe no orçamento fica abaixo do mínimo. A energia não gasta passa para as rodadas seguintes. Na última participação, o mínimo não vale. Com fração mínima 1,0, o cliente treina todos os dados ou pula.

Variante (α = 0,1, 8 seeds)	Média das 3 últimas	Diferença para o LeanFed-c [IC 95%], seeds melhores	Acurácia máxima	Particip.	Rodadas *dead*
LeanFed-c	74,8 ± 3,6%	—	77,5 ± 2,5%	285	0,8
fração mínima 0,3	76,6 ± 2,2%	**+1,9** [+0,6; +3,2], 7 de 8	79,4 ± 2,1%	270	0,4
fração mínima 0,5	77,3 ± 2,7%	**+2,5** [+1,0; +4,1], 7 de 8	80,1 ± 1,9%	260	0,4
fração mínima 0,7	77,6 ± 3,4%	**+2,9** [+1,9; +3,8], 8 de 8	80,0 ± 1,9%	251	0,4
fração mínima 1,0	**78,9 ± 3,1%**	**+4,1** [+1,9; +6,4], 8 de 8	80,0 ± 2,9%	240	0
margem de cauda 0,9	75,4 ± 3,6%	+0,6 [−0,8; +2,1], 4 de 8	77,3 ± 2,9%	278	0

- **A fração mínima é o único ajuste que melhora a acurácia**, e o ganho cresce com o mínimo: +1,9, +2,5, +2,9 e +4,1 pontos sobre o LeanFed-c com 0,3, 0,5, 0,7 e 1,0 (t pareado, p de 0,012 a < 0,001). Com 0,5, o efeito é o mesmo nas seeds 42 a 44 (+2,0)

e nas 45 a 49 (+2,8). Com 3 seeds, esse ganho parecia ruído.

- **Treinar uma fração dos dados não ajuda.** A melhor variante é a 1,0, que treina tudo ou pula: 78,9%, nenhuma rodada *dead* e +8,5 pontos sobre o FedAvg (IC 95% de +5,3 a +11,7; 8 de 8). A diferença para a 0,5 (+1,6; IC 95% de −0,3 a +3,6; p = 0,09) não é significativa, mas não há nenhum sinal a favor de frações menores. O que ajuda é pular rodadas para acumular energia. A fração 0,5 segue como valor de referência, e a varredura entra como análise de sensibilidade.
- **Contra o FedAvg, a fração mínima 0,5 ganha nas 8 seeds**: +6,8 pontos (IC 95% de +2,6 a +11,1; p = 0,007), contra +4,3 do LeanFed-c sem ela. As seeds 45 e 49, em que o LeanFed-c perdia, ficam em +2,5 e +0,1.
- **Diferente do LeanFed-c, a fração mínima também sobe o pico**: 80,1% contra 78,2% do FedAvg com 0,5 (+1,8 ponto pareado, 7 de 8 seeds, p = 0,002); 80,0% com 0,7 e 1,0.
- **Margem de cauda** (guardar o p90 da comunicação até a última participação): zera as mortes, mas não muda a acurácia (+0,6 ponto, 4 de 8 seeds). Depois de uma rodada de rede ruim no fim, o cliente pula as últimas rodadas em vez de morrer, e as classes dele somem do modelo do mesmo jeito.
- **Reserva por percentil** em vez da média (seed 42): o p90 evita mortes mas corta 47 participações; o p50 volta a perder clientes. A média ficou como padrão.

Custo fixo por rodada. Com D = 5 J (D ≈ C/5, como no exemplo do documento de custo de energia), FedAvg e LeanFed perdem cerca de 2,5 pontos, piores nas 8 seeds (67,9 ± 6,3% e 68,4 ± 6,3%), e o LeanFed morre mais (29 → 42 rodadas *dead*). O LeanFed-c, que já reserva D, fica igual (74,2 ± 3,3%; −0,5 ponto, não significativo). A vantagem dele sobre o FedAvg sobe para **+6,3 pontos** (IC 95% de +0,8 a +11,8; 6 de 8 seeds). Com 3 seeds, parecia de 10.

O que a fração mínima muda na participação

Os logs dos clientes mostram quando os 5 clientes de 500 J treinam (α = 0,1, média das 8 seeds). Os de 1000 e 1500 J participam de quase todas as rodadas em todas as políticas.

Clientes de 500 J	Ativos nas rodadas 1 a 7	Ativos nas rodadas 18 a 20	Exemplos treinados por rodada, rodadas 18 a 20
FedAvg	98%	8%	0,1 mil
LeanFed-c	91%	78%	3,8 mil
fração mínima 0,5	31%	85%	8,1 mil
fração mínima 0,7	23%	85%	9,4 mil
fração mínima 1,0	17%	94%	11,5 mil

- O FedAvg gasta a bateria dos clientes de 500 J no começo e chega ao fim sem eles. O LeanFed-c os mantém vivos, mas cada um treina pouco por rodada (no fim, 3,8 mil exemplos somados entre os 5).
- Com a fração mínima, esses clientes pulam o começo, acumulam energia e treinam quase todos os dados nas últimas rodadas. Quanto maior o mínimo, mais a participação

se concentra no fim, na mesma ordem do ganho da tabela acima.

- É o oposto de fazer os clientes frágeis contribuírem mais cedo: com a fração mínima, eles contribuem **tarde**, e com mais dados.

Acurácia por classe: o ganho não fica nas classes desses clientes

Para ver se o ganho vem das classes dos clientes de 500 J, o modelo final de cada run foi avaliado por classe no teste do CIFAR-10 (α = 0,1, 8 seeds). "Classes dos clientes de 500 J" são as que têm mais da metade dos exemplos de treino nesses clientes: de 2 a 4 por seed, 29% do total. Só existe o modelo da rodada 20, a da queda em todas as curvas, por isso a acurácia global é um pouco menor que a média das 3 últimas rodadas.

α = 0,1, rodada 20	Global	Classes dos clientes de 500 J	Outras classes	Pior classe
FedAvg	68,8%	68,0%	68,7%	21,2%
LeanFed-c	73,2%	75,1%	72,4%	32,8%
fração mínima 0,5	75,2%	77,1%	74,2%	39,6%
fração mínima 0,7	76,0%	81,3%	73,6%	40,0%
fração mínima 1,0	78,6%	80,1%	77,3%	46,2%

- **O ganho sobre o LeanFed-c se espalha.** A fração mínima 0,5 sobe +2,0 pontos nas classes dos clientes de 500 J e +1,9 nas outras. Essas classes levam 37% do ganho, quase a parte delas no total (29%), e a correlação entre o ganho de cada classe e a parte dela nesses clientes é fraca (Spearman +0,07 em média por seed; +0,15 com a fração 1,0), sem significância. Com α = 0,05 há alguma concentração (62% do ganho em 31% das classes), com intervalo largo.
- **A pior classe é a que mais sobe.** Com a fração 1,0, +13,5 pontos sobre o LeanFed-c (IC 95% de +5,3 a +21,6; 7 de 8 seeds) e +25,0 sobre o FedAvg (+8,5 a +41,5), contra +5,4 e +9,8 na acurácia global. Com a fração 0,5, +6,8 sobre o LeanFed-c, sem significância.
- **Então o ganho não vem das classes desses clientes.** A participação deles muda como a tabela anterior mostra, mas o ganho se espalha. A subseção seguinte mostra de onde ele vem.

De onde vem o ganho: mais exemplos treinados no total

Havia duas hipóteses. (1) As atualizações treinadas com poucos dados do LeanFed-c atrapalham o modelo global. Ela é fraca desde o início: a agregação já pesa cada cliente pelos exemplos que ele treinou na rodada. (2) A fração mínima faz entrar mais exemplos no treino. Os logs dos clientes mostram que entram: no α = 0,1, de 505 mil exemplos treinados em 20 rodadas no LeanFed-c para 563 mil com a fração 0,5 e 583 mil com a 1,0, na mesma ordem do ganho.

Isso acontece porque cada participação paga a rede (cerca de 23,5 J para baixar e enviar o modelo), seja qual for a fração dos dados treinada. Quando o cliente pula uma rodada, ele não gasta essa energia e pode usá-la para treinar. Com a fração 1,0, a energia de rede cai de 6,7 para 5,7 kJ e a de treino sobe de 4,5 para 5,2 kJ. Dois experimentos isolam esse

efeito (α = 0,1, 8 seeds):

- **Sem rádio** (*--radio-w 0*): a rede não custa nada, e pular uma rodada deixa de economizar energia. As baterias caem para 1025, 550 e 85 J, para a energia de treino ficar parecida com a do caso com rádio.
- **Com margem de cauda 0,9** nas três políticas: ninguém fica sem bateria, e a diferença na morte de clientes entre o LeanFed-c (1,6 clientes) e a fração mínima sai da comparação.

α = 0,1	Variante	Exemplos em 20 rodadas	Por rodada, 18 a 20	Sem bateria no fim	Média das 3 últimas	Diferença para o LeanFed-c [IC 95%], seeds melhores
Com rádio	LeanFed-c	505 mil	25,4 mil	1,6	74,8 ± 3,6%	—
	fração 0,5	563 mil	31,2 mil	1,2	77,3 ± 2,7%	**+2,5** [+1,0; +4,1], 7 de 8
	fração 1,0	583 mil	38,5 mil	0,1	78,9 ± 3,1%	**+4,1** [+1,9; +6,4], 8 de 8
Sem rádio	LeanFed-c	529 mil	26,4 mil	0,0	76,0 ± 2,2%	—
	fração 0,5	529 mil	31,1 mil	0,0	77,2 ± 2,9%	**+1,2** [−0,1; +2,5], 7 de 8
	fração 1,0	516 mil	36,1 mil	0,0	76,6 ± 3,1%	**+0,6** [−1,5; +2,7], 4 de 8
Margem de cauda	LeanFed-c	492 mil	27,7 mil	0,2	75,4 ± 3,6%	—
	fração 0,5	548 mil	33,5 mil	0,0	78,3 ± 2,5%	**+2,9** [+1,5; +4,4], 7 de 8
	fração 1,0	559 mil	38,4 mil	0,0	78,7 ± 3,8%	**+3,3** [+1,2; +5,5], 7 de 8

- **Sem rádio, o total de exemplos fica igual e o ganho quase some**: os três treinam cerca de 520 mil exemplos, e a fração mínima fica em +1,2 (0,5; p = 0,08) e +0,6 ponto (1,0; p = 0,5), contra +2,5 e +4,1 com rádio. A participação continua concentrada no fim (36 mil exemplos por rodada nas últimas rodadas com a fração 1,0, contra 26 mil no LeanFed-c), e a fração 1,0 é a que mais perde. Concentrar os dados no fim, sozinho, explica pouco.
- **Com margem de cauda, o ganho fica**: +2,9 (0,5; p = 0,002) e +3,3 pontos (1,0; p = 0,008) sobre o LeanFed-c com a mesma margem, sem ninguém sem bateria nas variantes com fração mínima. A diferença de exemplos também fica (492 mil contra 548 e 559 mil). A morte de clientes no fim do LeanFed-c não explica o ganho.
- **O ganho vem de treinar mais exemplos no total**, com a energia que a fração mínima deixa de gastar com a rede. Por isso ele não fica nas classes dos clientes de 500 J: o que muda é a quantidade de dados que entra no treino inteiro. Com a margem de cauda, a fração 0,5 chega a 78,3% (+1,0 ponto sobre ela sem margem, sem significância); a 1,0 fica igual (78,7%).
- Seed a seed, a relação é mais fraca. Com a fração 1,0, a seed que ganha mais exemplos sobre o LeanFed-c tende a ganhar mais acurácia (Spearman +0,71, p = 0,05); com a 0,5, não (+0,12). Com 8 seeds, uma diferença de ~60 mil exemplos (cerca de 10%) é pequena diante da variação entre seeds.

A fração mínima 0,5 nos outros α

α	FedAvg	LeanFed-c	Fração mínima 0,5	Fração 0,5 − LeanFed-c [IC 95%], seeds melhores	Fração 0,5 − FedAvg [IC 95%], seeds melhores
0,05	48,0 ± 10,8%	57,1 ± 10,9%	64,3 ± 8,3%	**+7,3** [+2,5; +12,1], 8 de 8	**+16,3** [+10,5; +22,2], 8 de 8
0,1	70,4 ± 6,0%	74,8 ± 3,6%	77,3 ± 2,7%	**+2,5** [+1,0; +4,1], 7 de 8	**+6,8** [+2,6; +11,1], 8 de 8
0,3	84,3 ± 1,5%	84,9 ± 0,8%	85,9 ± 0,6%	**+1,0** [+0,7; +1,4], 8 de 8	**+1,6** [+0,8; +2,5], 7 de 8
1,0	87,6 ± 0,5%	87,2 ± 0,5%	87,7 ± 0,5%	**+0,5** [+0,3; +0,7], 8 de 8	**+0,1** [−0,2; +0,5], 4 de 8

- **Melhora o LeanFed-c em todos os α**, em 8 de 8 seeds em α = 0,05, 0,3 e 1,0. A diferença diminui quando as classes se espalham, como o próprio ganho do LeanFed-c (seção 4).
- **Com α = 0,05, o ganho sobre o FedAvg quase dobra**: +16,3 pontos contra +9,1 do LeanFed-c sozinho. O pico também passa a ser maior que o do FedAvg (+3,7 pontos, 8 de 8); sem a fração mínima, o LeanFed-c ficava 4,2 pontos abaixo (0 de 8).
- **Com α = 0,3**, o ganho sobre o FedAvg passa a ser significativo: +1,6 pontos (7 de 8, p = 0,003), contra +0,6 sem significância do LeanFed-c.
- **Com α = 1,0, elimina o custo do LeanFed-c**: empata com o FedAvg (+0,1, 4 de 8; pico 88,0% nos dois), onde o LeanFed-c ficava 0,4 ponto abaixo.

A fração mínima 0,5 no FEMNIST

Partição	FedAvg	LeanFed-c	Fração mínima 0,5	Fração 0,5 − LeanFed-c [IC 95%], seeds melhores	Fração 0,5 − FedAvg [IC 95%], seeds melhores
Dirichlet α = 0,1	74,7 ± 2,5%	76,0 ± 1,8%	78,7 ± 1,6%	**+2,7** [+1,3; +4,1], 8 de 8	**+4,0** [+1,8; +6,2], 8 de 8
por escritor	84,5 ± 0,3%	84,3 ± 0,3%	84,7 ± 0,3%	**+0,4** [+0,3; +0,5], 8 de 8	**+0,2** [+0,1; +0,3], 7 de 8

- **Com Dirichlet α = 0,1, é a melhor política**: +2,7 pontos sobre o LeanFed-c e +4,0 sobre o FedAvg, nas 8 seeds nos dois casos (p = 0,003 e 0,004). O LeanFed-c sozinho ganha +1,3 do FedAvg, sem significância. O pico também sobe: 79,4% contra 77,6% do FedAvg e 76,7% do LeanFed-c.
- **Por escritor, os três empatam na prática** (84,3% a 84,7%). A fração 0,5 ainda fica à frente do FedAvg (+0,2; 7 de 8) e do LeanFed-c (+0,4; 8 de 8), e o LeanFed-c sozinho fica 0,2 ponto abaixo do FedAvg (2 de 8), como no CIFAR-10 com α = 1,0.
- É o que se esperava antes das runs: ganho na partição Dirichlet e empate por escritor, onde nenhuma classe fica concentrada nos clientes que o FedAvg perde (seção 4).

O que só foi medido no α = 0,1 do CIFAR-10. As frações 0,3, 0,7 e 1,0, a margem de cauda, o custo fixo D = 5 e os experimentos sem rádio e com margem de cauda na fração mínima.

4. O ganho depende da concentração de classes

Pergunta. O LeanFed-c mantém os clientes vivos em todos os cenários. Quando isso vale acurácia? Foram testados dois tipos de cenário, cada um com FedAvg e LeanFed-c (8 seeds em cada):

- **FEMNIST** (caracteres escritos à mão, 62 classes, 12 pessoas por cliente), dividido **por escritor**, que é a partição natural, ou por **Dirichlet α = 0,1**, com as mesmas pessoas.
- **CIFAR-10 variando o α** da partição Dirichlet: 0,05, 0,1, 0,3 e 1,0. Só o α muda; quanto menor, mais cada classe fica concentrada em poucos clientes.

Cenário	n	FedAvg (%)	LeanFed-c (%)	Ganho [IC 95%]	Seeds com ganho	Dados perdidos pelo FedAvg	Classes com >80% perdidas
CIFAR-10, α = 0,05	8	48,0 ± 10,8	57,1 ± 10,9	**+9,1** [+4,6; +13,5]	8 de 8	58%	39%
CIFAR-10, α = 0,1	8	70,4 ± 6,0	74,8 ± 3,6	**+4,3** [−0,1; +8,8]	6 de 8	55%	32%
CIFAR-10, α = 0,3	8	84,3 ± 1,5	84,9 ± 0,8	**+0,6** [−0,3; +1,5]	6 de 8	45%	5%
CIFAR-10, α = 1,0	8	87,6 ± 0,5	87,2 ± 0,5	**−0,4** [−0,8; +0,0]	1 de 8	41%	0%
FEMNIST, Dirichlet α = 0,1	8	74,7 ± 2,5	76,0 ± 1,8	**+1,3** [−0,1; +2,7]	6 de 8	42%	16%
FEMNIST, por escritor	8	84,5 ± 0,3	84,3 ± 0,3	**−0,2** [−0,3; −0,0]	2 de 8	33%	0%

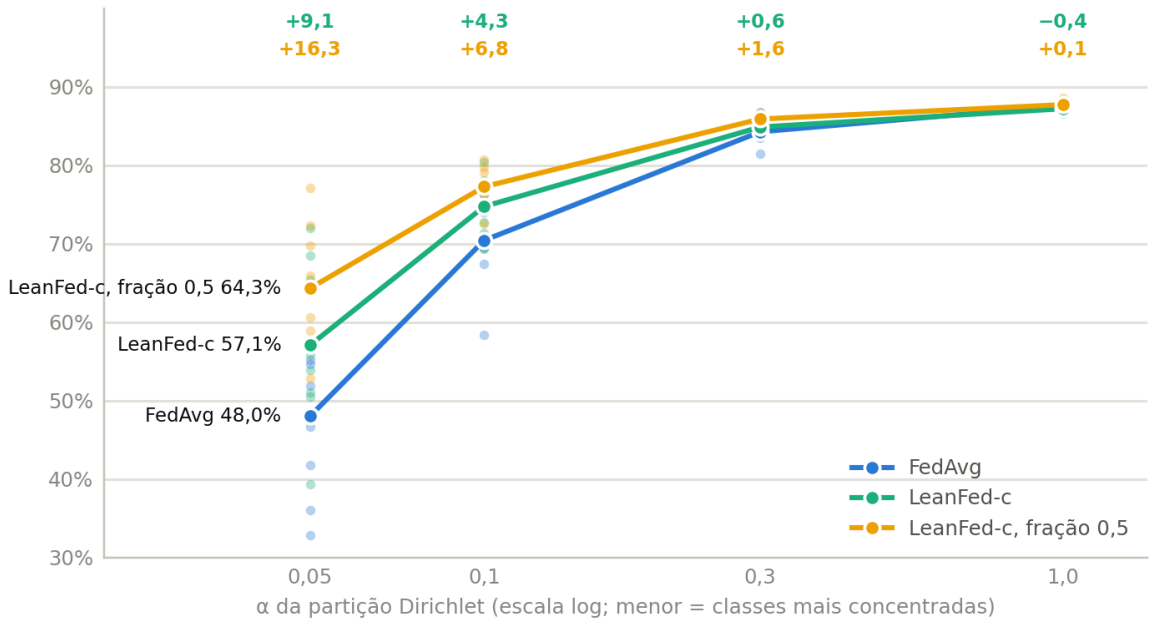


Figura 2. Acurácia média das 3 últimas rodadas contra o α do CIFAR-10, 8 seeds por ponto. Os pontos claros são as seeds; no alto, o ganho médio sobre o FedAvg, na cor de cada método. Todos pioram quando o α diminui; o FedAvg piora mais. A fração mínima 0,5 (seção 3) fica acima do LeanFed-c em todos os α.

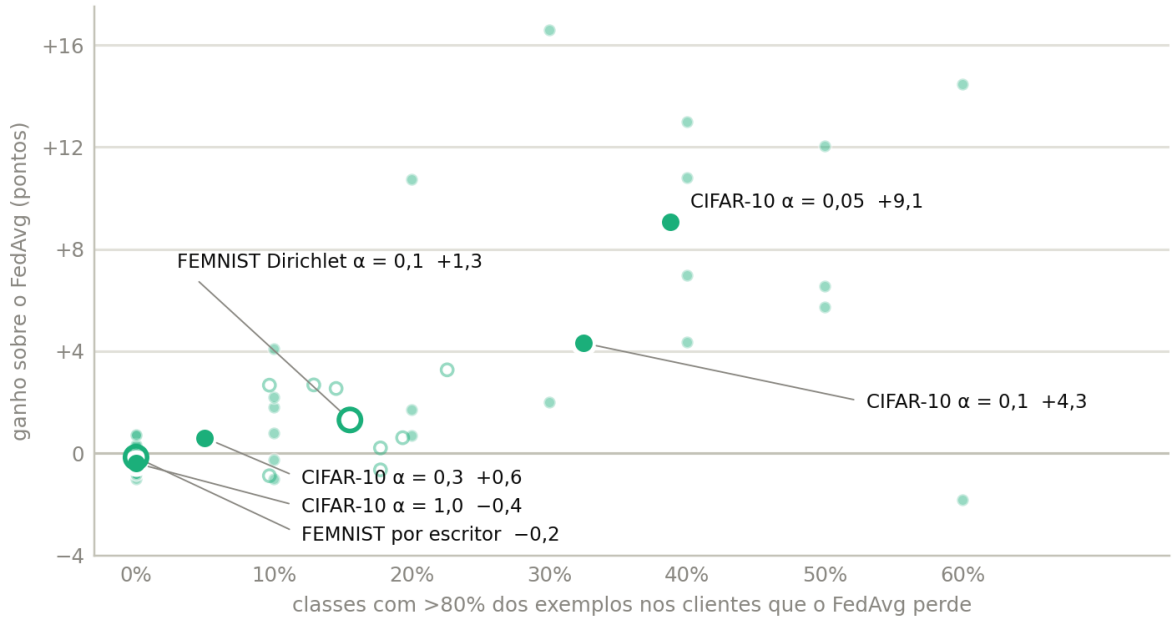


Figura 3. Ganho do LeanFed-c contra a fração de classes concentradas nos clientes que o FedAvg perde. Cada ponto pequeno é uma seed (8 por cenário); o grande, a média do cenário. CIFAR-10 preenchido, FEMNIST vazado.

O que os números dizem.

- **Perder dados não custa; perder classes custa.** O FedAvg perde de 32% a 58% dos dados de treino em todos os cenários, mas só fica atrás quando as classes estão concentradas nos clientes que saem. Com α = 0,3, ele perde 45% dos dados e 5% das classes, e o ganho do LeanFed-c é de 0,6 ponto, sem significância (IC 95% de −0,3 a

+1,5).

- **A acurácia por classe confirma.** No modelo da rodada 20 com α = 0,1, 74% do ganho do LeanFed-c sobre o FedAvg (87% do da fração mínima 0,5) está nas classes concentradas nos clientes que o FedAvg perde, que são 32% das classes. Nelas, o FedAvg acerta 54,8%, o LeanFed-c 67,2% e a fração 0,5 72,1%; nas outras, os três ficam entre 75% e 77%. Com α = 0,05, 93% do ganho do LeanFed-c está em 39% das classes.
- **O resultado se repete no mesmo dataset.** A comparação entre CIFAR-10 e FEMNIST mudava o dataset junto com a partição. A varredura do α muda só a concentração e reproduz a mesma relação: +9,1, +4,3, +0,6 e −0,4 pontos de α = 0,05 a α = 1,0.
- **O FEMNIST segue a mesma relação.** Com Dirichlet α = 0,1, 16% das classes ficam concentradas e o ganho do LeanFed-c é de +1,3 ponto (IC 95% de −0,1 a +2,7; 6 de 8), entre os do α = 0,1 e do α = 0,3 do CIFAR-10. Por escritor, nenhuma classe fica concentrada e o LeanFed-c fica 0,2 ponto abaixo, como no α = 1,0.
- **Só α = 0,05 tem ganho firme.** Positivo nas 8 seeds (de +0,7 a +16,6; t pareado p = 0,002). Em α = 0,1 o intervalo encosta no zero.
- **Sem concentração, o LeanFed-c custa pouco.** Com α = 1,0 ele fica abaixo do FedAvg em 7 das 8 seeds (−0,4 ponto, IC 95% de −0,8 a 0,0), e a acurácia máxima também é menor (87,4% contra 88,0%). Sem classes a proteger, sobra só o custo de treinar menos dados por rodada. Com a fração mínima 0,5, esse custo some (seção 3).
- **O ganho é relativo.** Com α menor os dois métodos pioram (Figura 2). O LeanFed-c não fica melhor com dados mais heterogêneos; ele resiste melhor a um cenário pior.
- **A relação vale entre cenários, não seed a seed.** Dentro de um mesmo α, a fração de classes concentradas não prevê o ganho (correlação de Spearman 0,30 com α = 0,05 e 0,14 com α = 0,1, ambas não significativas). Na seed 45 com α = 0,1, 60% das classes ficam concentradas e o ganho é negativo (seção 2); na seed 44 com α = 0,05, 50% e o ganho é dos menores (+6,5), porque os dois modelos vão mal (39% e 33%).

5. Conclusões, limitações e próximos passos

O que já se pode afirmar

- Com comunicação realista, o LeanFed original não é melhor que o FedAvg. A correção que reserva comunicação e custo fixo é o que faz a política funcionar.
- O LeanFed-c traz ganho quando a heterogeneidade é de rótulo e as classes se concentram em clientes com bateria limitada. Com 8 seeds no CIFAR-10, o ganho é claro com α = 0,05 (+9,1 pontos, 8 de 8 seeds) e provável com α = 0,1 (+4,3, 6 de 8, p = 0,055). No FEMNIST com Dirichlet, +1,3 (6 de 8, p = 0,06). Sem essa concentração, ele empata com o FedAvg ou fica até 0,4 ponto abaixo.
- O ganho do LeanFed-c vem de manter os clientes de bateria pequena, e as classes deles, até o fim do treino: a acurácia por classe mostra que três quartos do ganho estão nas classes que o FedAvg perde. O pico de acurácia não melhora.
- A fração mínima 0,5 melhora o LeanFed-c nos quatro α do CIFAR-10 (+7,3 a +0,5 pontos) e o deixa à frente do FedAvg em α = 0,05, 0,1 e 0,3 (+16,3, +6,8 e +1,6),

empatado em α = 1,0, com pico maior ou igual em todos. No FEMNIST, ganha +4,0 do FedAvg com Dirichlet (8 de 8) e +0,2 por escritor. É a melhor política medida em todos os cenários.

- O ganho da fração mínima vem de pular rodadas, e não de treinar uma fração dos dados: os clientes de bateria pequena guardam energia no começo e treinam todos os dados no fim. No α = 0,1, "treina tudo ou pula" (fração 1,0) é a melhor variante (+4,1 sobre o LeanFed-c, +8,5 sobre o FedAvg). O ganho sobre o LeanFed-c se espalha pelas classes, e a pior classe sobe mais que a média (+13,5 com a fração 1,0). Ele vem de treinar mais exemplos no total com a energia de rede que as rodadas puladas economizam: sem custo de rádio, o ganho cai para +1,2 e +0,6 ponto, sem significância; sem mortes (margem de cauda), ele fica.
- Para comparar políticas, usar a média das últimas rodadas e várias seeds; a acurácia de uma rodada e de uma seed é ruído. Três seeds não bastam: no α = 0,1, as seeds 42 a 44 deram o dobro do ganho do LeanFed-c medido com 8, e o ganho com D = 5 caiu de 10 para 6,3 pontos. Já a fração mínima, que com 3 seeds parecia ruído, se confirmou com 8.
- Com MobileNetV3 e dados não-IID, a média das estatísticas da BatchNorm feita pela FedAvg distorce a acurácia do modelo global no FEMNIST; para comparar métodos, é preciso recalibrá-las antes de avaliar (seção 1).

Limitações

- A fração mínima 0,5 tem os quatro α do CIFAR-10 e as duas partições do FEMNIST; as frações 0,3, 0,7 e 1,0, a margem de cauda e D = 5, só o α = 0,1 do CIFAR-10.
- No FEMNIST, a BatchNorm só é recalibrada na avaliação: os clientes continuam recebendo a média das estatísticas. Não se sabe se recalibrar também no modelo enviado (ou trocar a BatchNorm por GroupNorm) mudaria o treino, nem por que a distorção varia de 5 a 16 pontos entre os métodos.
- A causa do ganho da fração mínima (mais exemplos no total) só foi testada no α = 0,1 do CIFAR-10, e depende do custo do rádio: com rede mais barata ou mais cara, o ganho deve mudar junto. A acurácia por classe só foi medida no modelo da rodada 20, porque os das outras rodadas não são salvos, e não se sabe se o ganho depende de parar o treino na rodada 20.
- A fração de classes concentradas explica a diferença entre cenários, mas não entre seeds do mesmo cenário: falta uma medida que preveja quando o FedAvg realmente degrada no fim.
- Setup único: uma faixa de rede (25 Mbps), sem diferença de potência entre clientes, sem recarga. A energia vem do perfil de uma GPU de desktop, não de um celular.
- As mortes no fim por uma rodada de rede ruim continuam sem solução: a margem de cauda troca a morte por rodadas puladas.
- Só existe o modelo completo: os submodelos de largura variável ainda não foram implementados.

Próximos passos

- Variar a potência do rádio (por exemplo 0,9 e 3,6 W) para ver se o ganho da fração mínima acompanha a energia de rede economizada.
- Entender os casos em que o FedAvg perde classes e não degrada (seed 45 com α = 0,1), com a acurácia por classe (*scripts/class_accuracy.py*).
- Reavaliar a ideia de fazer os clientes frágeis contribuírem mais cedo: a fração mínima ganha fazendo o contrário.
- Variar o setup (faixas de rede, baterias, potência por cliente) para ver se a vantagem se mantém.
- Submodelos de largura variável (HeteroFL), para comparar "reduzir dados" (LeanFed-c) com "reduzir modelo".
- Para decidir: um terceiro dataset como o EuroSAT só faz sentido se a dissertação mirar sensoriamento remoto, porque repete a condição do CIFAR-10 (10 classes, sem partição natural).

Apêndice A. Runs e como reproduzir

Pastas em *outputs/* (prefixo do id). Todas com o cenário da seção 1; cada linha muda só o que o nome diz. As runs do FEMNIST são as com *bn-recalibrate=true* (lote de 23/10), que repetem as anteriores com a mesma acurácia original e acrescentam a recalibrada. As demais runs estão no apêndice do histórico.

Cenário e política	Seed 42	Seed 43	Seed 44
CIFAR-10 α = 0,05: FedAvg	17512...	15739...	68363...
CIFAR-10 α = 0,05: LeanFed-c	13324...	56224...	74911...
CIFAR-10 α = 0,05: fração mínima 0,5	74231...	39955...	21686...
CIFAR-10 α = 0,1: FedAvg	1977...	18006...	10759...
CIFAR-10 α = 0,1: LeanFed	16069...	11656...	11938...
CIFAR-10 α = 0,1: LeanFed-c	10494...	12096...	4501...
CIFAR-10 α = 0,1: fração mínima 0,3	70223...	12763...	12243...
CIFAR-10 α = 0,1: fração mínima 0,5	57608...	11724...	21629...
CIFAR-10 α = 0,1: fração mínima 0,7	94830...	11212...	36821...
CIFAR-10 α = 0,1: fração mínima 1,0	39105...	11630...	13244...
CIFAR-10 α = 0,1: margem de cauda 0,9	17135...	16908...	11427...
CIFAR-10 α = 0,1: fração 0,5 e margem de cauda 0,9	67067...	56917...	91968...
CIFAR-10 α = 0,1: fração 1,0 e margem de cauda 0,9	15522...	18252...	10244...
CIFAR-10 α = 0,1, sem rádio: LeanFed-c	56265...	11039...	11506...
CIFAR-10 α = 0,1, sem rádio: fração mínima 0,5	11059...	17811...	75048...

Cenário e política	Seed 42	Seed 43	Seed 44
CIFAR-10 α = 0,1, sem rádio: fração mínima 1,0	53248…	34449…	97914…
CIFAR-10 α = 0,1, D = 5: FedAvg	99297…	14583…	15387…
CIFAR-10 α = 0,1, D = 5: LeanFed	41686…	16970…	12657…
CIFAR-10 α = 0,1, D = 5: LeanFed-c	10067…	10184…	98610…
CIFAR-10 α = 0,3: FedAvg	11428…	40976…	15233…
CIFAR-10 α = 0,3: LeanFed-c	14875…	52897…	68942…
CIFAR-10 α = 0,3: fração mínima 0,5	10723…	10638…	15043…
CIFAR-10 α = 1,0: FedAvg	12018…	21996…	11654…
CIFAR-10 α = 1,0: LeanFed-c	17183…	69488…	15431…
CIFAR-10 α = 1,0: fração mínima 0,5	18343…	49975…	67601…
FEMNIST escritor: FedAvg	29553…	14431…	10766…
FEMNIST escritor: LeanFed-c	14878…	28328…	12001…
FEMNIST escritor: fração mínima 0,5	17757…	44950…	10449…
FEMNIST Dirichlet: FedAvg	12511…	15898…	72012…
FEMNIST Dirichlet: LeanFed-c	88227…	19479…	59824…
FEMNIST Dirichlet: fração mínima 0,5	45006…	95189…	12909…

Cenário e política	Seed 45	Seed 46	Seed 47	Seed 48	Seed 49
CIFAR-10 α = 0,05: FedAvg	11973…	10618…	13286…	18104…	75581…
CIFAR-10 α = 0,05: LeanFed-c	17529…	19458…	80657…	10299…	40953…
CIFAR-10 α = 0,05: fração mínima 0,5	94595…	16242…	15379…	33992…	11574…
CIFAR-10 α = 0,1: FedAvg	84285…	72545…	11917…	11541…	13836…
CIFAR-10 α = 0,1: LeanFed	12960…	14051…	63580…	13382…	92632…
CIFAR-10 α = 0,1: LeanFed-c	12443…	15957…	22576…	91925…	40049…
CIFAR-10 α = 0,1: fração mínima 0,3	58980…	14473…	90559…	83106…	97801…
CIFAR-10 α = 0,1: fração mínima 0,5	17593…	38953…	74931…	13337…	13428…
CIFAR-10 α = 0,1: fração mínima 0,7	10531…	68311…	13025…	14309…	92826…
CIFAR-10 α = 0,1: fração mínima 1,0	79835…	14346…	13550…	17814…	57671…
CIFAR-10 α = 0,1: margem de cauda 0,9	80290…	14219…	18360…	15014…	24191…

Cenário e política	Seed 45	Seed 46	Seed 47	Seed 48	Seed 49
CIFAR-10 α = 0,1: fração 0,5 e margem de cauda 0,9	58638...	73913...	62442...	24803...	38960...
CIFAR-10 α = 0,1: fração 1,0 e margem de cauda 0,9	92410...	15962...	15879...	15497...	69158...
CIFAR-10 α = 0,1, sem rádio: LeanFed-c	36352...	76661...	82841...	62932...	99753...
CIFAR-10 α = 0,1, sem rádio: fração mínima 0,5	62209...	15923...	26993...	18326...	94229...
CIFAR-10 α = 0,1, sem rádio: fração mínima 1,0	25801...	15356...	12690...	18217...	17036...
CIFAR-10 α = 0,1, D = 5: FedAvg	16348...	58377...	55821...	18038...	63194...
CIFAR-10 α = 0,1, D = 5: LeanFed	43062...	39301...	17083...	13518...	13321...
CIFAR-10 α = 0,1, D = 5: LeanFed-c	55191...	12880...	10570...	10191...	16714...
CIFAR-10 α = 0,3: FedAvg	48566...	14967...	14939...	15273...	15319...
CIFAR-10 α = 0,3: LeanFed-c	48229...	10455...	13603...	14944...	10437...
CIFAR-10 α = 0,3: fração mínima 0,5	16108...	15101...	15890...	21442...	17025...
CIFAR-10 α = 1,0: FedAvg	60910...	13293...	12234...	84912...	14615...
CIFAR-10 α = 1,0: LeanFed-c	20015...	13867...	16467...	37089...	75707...
CIFAR-10 α = 1,0: fração mínima 0,5	88964...	27903...	58342...	18979...	15558...
FEMNIST escritor: FedAvg	14499...	13120...	12118...	15009...	14904...
FEMNIST escritor: LeanFed-c	12487...	15266...	10577...	13214...	15799...
FEMNIST escritor: fração mínima 0,5	46534...	50927...	14157...	32677...	11099...
FEMNIST Dirichlet: FedAvg	16578...	18360...	16197...	44154...	81443...
FEMNIST Dirichlet: LeanFed-c	17665...	15770...	70768...	13113...	18339...
FEMNIST Dirichlet: fração mínima 0,5	19907...	77329...	16194...	15101...	59879...

Com os containers de pé (*./run.sh -n 15 -b 1500,1000,500 --net-mbps 25*):

```
# lotes (um por cenário)
./scripts/run_seeds.sh -v fedavg,leanfed,leanfed-c 42 43 44           # CIFAR-10, α = 0,1
./scripts/run_seeds.sh -v fedavg,leanfed,leanfed-c 45 46 47 48 49     # seeds extras
./scripts/run_seeds.sh -v leanfed-c-mdf0.3,leanfed-c-mdf0.5,leanfed-c-tail0.9 42 43 44 45 46 47 48 49
./scripts/run_seeds.sh -x "energy-fixed-j=5.0" -v fedavg,leanfed,leanfed-c 42 43 44 45 46 47 48 49
./scripts/run_seeds.sh -v leanfed-c-mdf0.7,leanfed-c-mdf1.0 42 43 44 45 46 47 48 49
./scripts/run_seeds.sh -x "tail-margin=0.9" -v leanfed-c-mdf0.5,leanfed-c-mdf1.0 42 43 44 45 46 47 48 49
# sem rádio: subir antes ./run.sh -n 15 -b 1025,550,85 --net-mbps 25 --radio-w 0
./scripts/run_seeds.sh -v leanfed-c,leanfed-c-mdf0.5,leanfed-c-mdf1.0 42 43 44 45 46 47 48 49
./scripts/run_seeds.sh -d cifar10-a0.3 -v fedavg,leanfed-c 42 43 44   # ou a0.05, a1.0
./scripts/run_seeds.sh -d cifar10-a0.3 -v leanfed-c-mdf0.5 42 43 44 45 46 47 48 49
./scripts/run_seeds.sh -d femnist -x "bn-recalibrate=true" \
    -v fedavg,leanfed-c,leanfed-c-mdf0.5 42 43 44 45 46 47 48 49   # ou -d femnist-dirichlet
# média ± desvio, classes perdidas e ganho pareado (o --ref escolhe o cenário)
python3 scripts/seeds_summary.py --ref 1977  -o graficos/seeds         # α = 0,1 e variantes
python3 scripts/seeds_summary.py --ref 5626  -o graficos/seeds-sem-radio
python3 scripts/seeds_summary.py --ref 11428 -o graficos/seeds-alfa-0.3
python3 scripts/class_loss.py    --ref 11428 -o graficos/seeds-alfa-0.3
python3 scripts/seeds_summary.py --bn --ref 38162 -o graficos/seeds-femnist-dirichlet
python3 scripts/class_loss.py    --bn --ref 38162 -o graficos/seeds-femnist-dirichlet
python3 scripts/seeds_summary.py --bn --ref 10788 -o graficos/seeds-femnist   # escritor
# acurácia por classe do final_model.pt e parte de cada classe por bateria (na CPU)
docker run --rm -v aprendfed_data:/data:ro -v "$PWD":/app:ro aprendfed:latest \
    python scripts/class_accuracy.py [--bn] outputs/run-<id>-<data> ...
# Figura 3 a partir dos perda_classes.csv
python3 scripts/plot_gain_classes.py --ext pdf
```